Justiça e IA: um protocolo formal pode decidir de forma enviesada?

0.1 Metodologia

Pergunta. O trabalho testa a tese de que mesmo uma IA que segue um protocolo formal pode produzir decisões enviesadas. O objeto é o tráfico de drogas (art. 33 da Lei 11.343/2006) e, em particular, a causa de diminuição do §4º ("tráfico privilegiado"), que é o pedido mais frequente nos recursos e depende de critérios que a lei não define com precisão.

Fontes. Foram usados três tipos de dado, todos públicos:

1. **Espelhos de acórdãos do STJ** (dados abertos, JSON mensal), da 5ª e da 6ª Turma, que são as turmas criminais do tribunal. Período: junho a agosto de 2026. Os meses de março a maio foram descartados porque têm poucas decisões por mês e uma taxa de vitória da defesa muito acima dos demais, o que indica uma seleção, e não o conjunto completo.
2. **Processos individuais** obtidos na consulta processual do STJ: um CSV com as partes, fases e petições e os PDFs das decisões (acórdãos e monocráticas).
3. **Texto legal** vigente da Lei 11.343/2006 e do Código Penal.

Recorte e unidade de análise. Entram os processos de tráfico (art. 33 e §4º), com condenação já proferida. Ficam fora: associação (art. 35) sem art. 33, medidas cautelares, execução penal, atos infracionais (ECA) e o art. 37. A unidade é o réu. O alvo é o resultado *para o réu*: um recurso do Ministério Público que é negado conta como resultado favorável.

Classificação das ementas. Um script (`scripts/analisar_ementas.py`) classifica cada acórdão só pelo texto da ementa e do dispositivo: quem recorreu, o que foi decidido, o resultado para o réu, as barreiras processuais citadas (Súmulas 7, 182, 83, 284/STF, habeas corpus substitutivo) e expressões sobre a pessoa ou o lugar ("vulgo", facção, "local conhecido" etc.). São regras fixas (expressões regulares), sem aprendizado. A classificação foi conferida contra os casos lidos por inteiro: [**A FAZER:** tabela de validação: 5ª Turma 32/33; 6ª Turma 29/30; base do §4º 16/19].

Amostras lidas por inteiro. Foram sorteadas 40 decisões por turma, estratificadas por relator (semente 2026), e lidas por inteiro. A extração dos fatos (droga, quantidade, antecedentes, fundamentos de cada instância) foi feita com apoio de um modelo de linguagem seguindo um protocolo escrito (`extracao/protocolo_extracao.md`), com conferência manual de uma parte dos casos. [**A FAZER:** número de casos conferidos e concordância].

Base do §4º. Para ter os fatos que a lei exige, montou-se uma base focada só nos pedidos de §4º feitos pela defesa (`scripts/sortear_p4.py`). O desenho é de caso-controle: entram todas as vitórias da defesa, que são raras, e oito derrotas sorteadas por relator; cada derrota recebe um peso para corrigir o sorteio. A extração segue um protocolo próprio (`extracao/protocolo_p4.md`).

Árvore A: o "juiz virtual" (protocolo formal)

A árvore A é a lei escrita como regras em Prolog (`prolog/arvore_a.pl`). O §4º exige quatro requisitos cumulativos:

> "as penas poderão ser reduzidas de um sexto a dois terços [...] desde que o agente seja primário, de bons antecedentes, não se dedique às atividades criminosas nem integre organização criminosa."

Dois pontos do texto não dizem *como* decidir: o que conta como "dedicar-se às atividades criminosas" e onde, entre 1/6 e 2/3, fica a fração (o art. 42 manda considerar a natureza e a quantidade da droga, sem dizer quanto). Para transformar a lei em programa é preciso escolher. Na árvore A, cada escolha é um **parâmetro** explícito, e um conjunto de escolhas forma um **perfil**. A estrutura da árvore é a mesma para todos os perfis.

```
requisito(primario, C, _, nao_atende) :- status(reincidente, C, sim), !.
requisito(nao_dedica, C, P, R) :-
    dedica(C, P, D, _), ( D == sim -> R = nao_atende ; R = atende ).

dedica(C, P, D, Indicadores) :-
    findall(I, indicador(C, P, I), L0), sort(L0, Indicadores),
    length(Indicadores, N), param(P, minimo_indicadores(M)),
    (   N >= M -> D = sim
    ;   param(P, quantidade_isolada_basta(sim)),
        memberchk(quantidade(_), Indicadores) -> D = sim
    ;   D = nao ).
```

Os parâmetros, e os três perfis usados como referência, estão na Tabela 1. Os perfis são parametrizações ilustrativas, ancoradas em leituras que aparecem nas decisões estudadas (por exemplo, a decisão monocrática que concedeu o §4º para 432 kg de maconha e o acórdão da Turma que a reformou); não pretendem retratar ministros.

Tabela 1: Parâmetros da árvore A e os três perfis de referência.

Parâmetro	garantista	intermediário	restritivo
Quantidade indica dedicação?	não	sim	sim
Quantidade sozinha basta?	não	não	sim
Limite (maconha / cocaína, g)	—	10.000 / 1.000	1.000 / 100
Atos infracionais contam (janela)	não	3 anos	5 anos
Ações penais em curso contam?	não	não (Tema 1.139)	sim
"Esquecimento" de antecedentes	5 anos	não	não
Indícios aceitos	arma, facção	+ petrechos, celular, investigação, logística	+ denúncias, local, dinheiro, variedade
Mínimo de indicadores	2	2	1

Três decisões de projeto merecem registro:

- **Dado faltante.** Cada fato tem três valores: sim, não ou desconhecido. O que fazer com o desconhecido ("na dúvida, a favor do réu" ou "cabe à defesa provar") é um eixo separado do perfil e é testado à parte.
- **Lei no tempo.** A data do fato define a lei aplicável: antes de 8/10/2006 valia a Lei 6.368/1976, sem tráfico privilegiado.
- **Pena.** Para isolar o efeito do §4º, a pena-base é fixada no mínimo (5 anos), a majorante do art. 40 em 1/6, e o regime e a substituição seguem os arts. 33, §2º, e 44 do Código Penal.

A árvore também explica a decisão (`explica/2`): quais requisitos falharam e quais indicadores de dedicação foram usados.

Árvore B: a árvore aprendida das decisões

A árvore B é uma árvore de decisão (CART, `scikit-learn`) treinada nas decisões reais e convertida em regras Prolog (`scripts/arvore_b.py` gera `prolog/arvore_b.pl`).

- **Dados:** acórdãos de tráfico da 5ª e da 6ª Turma, só recursos da defesa (no recurso do MP o réu quase sempre ganha, o que seria uma regra trivial).
- **Alvo:** a defesa vence (resultado favorável ou parcial) ou perde.
- **Entradas:** o que se sabe antes do julgamento: turma, relator, classe do processo, assunto e marcadores da ementa.
- **Excluídas, por vazamento:** as barreiras processuais, o dispositivo, a votação e se o relator ficou vencido, porque fazem parte da própria decisão.
- **Modelo:** profundidade máxima 4, ao menos 10 casos por folha, classes balanceadas.
- **Dois modelos:** *com relator* (todas as entradas) e *sem relator* (sem turma e sem relator).

O objetivo não é prever bem. Com cerca de 97% de derrotas, um modelo que sempre responde "perde" já acerta 97%. O que interessa é *o que* a árvore aprende a perguntar.

Testes

As duas árvores têm testes automáticos (`plunit`):

- **Árvore A** (`prolog/testes_arvore_a.pl`, 26 testes com casos sintéticos): cobrem a lei no tempo, cada requisito, cada critério vago (Tema 1.139, quantidade, atos infracionais, esquecimento), o dado faltante e a pena.
- **Árvore B** (`prolog/testes_arvore_b.pl`): confirmam que as regras em Prolog dão exatamente a mesma resposta que o modelo treinado em todos os processos.

0.2 Experimentos Computacionais

[**A FAZER:** Esta seção será escrita depois. Abaixo, os experimentos planejados.]

E1. Sensibilidade da árvore A. Os mesmos réus reais (base do §4º e amostras) são julgados pelos três perfis, com dado faltante tratado a favor do réu e contra ele. Medida: em quantos casos a decisão (concede/nega) ou a fração muda só pela escolha dos parâmetros. [**A FAZER:** tabela]

E2. Casos com relator vencido. Nos processos em que o relator concedeu o §4º e a Turma reformou, verificar qual perfil reproduz cada uma das duas decisões. [**A FAZER:** tabela]

E3. O que a árvore B aprende. Comparar as regras e as variáveis usadas pelos modelos com e sem relator; validação cruzada estratificada e "deixa um relator fora". Métricas para a classe rara (recall e precisão das vitórias), e não acurácia. [**A FAZER:** regras e métricas]

E4. Árvore A × árvore B × decisão real. Onde o protocolo formal e o modelo aprendido concordam e discordam entre si e com o que o STJ decidiu. [**A FAZER:** tabela]

Limitações. [**A FAZER:** só acórdãos (as monocráticas favoráveis sem recurso não aparecem); extração com apoio de IA; amostras pequenas por relator; perfis ilustrativos.]